

# 머신러닝 성능 지표 한눈에 보기

RMSE,  $R^2$  Score, Accuracy, F1 Score처럼 모델의 성능을 판단할 때 자주 쓰는 지표들을 문제 유형별로 정리한 짧은 교재입니다.

## 회귀

연속값 예측의 오차를 해석합니다.

## 분류

맞춤, 오탐, 미탐의 균형을 봅니다.

## 랭킹/추천

상위 K개 결과의 품질을 평가합니다.

# 목차

---

1. 성능 지표를 고르는 기준
2. 회귀 모델 지표
3. 분류 모델 지표
4. 군집 모델 지표
5. 추천·랭킹 지표
6. 자연어 처리·생성 모델 지표
7. 실무에서 지표를 선택하는 방법
8. 점수 범위와 결과 해석
9. 빠른 요약표

# 1. 성능 지표를 고르는 기준

머신러닝 모델의 성능 지표는 “모델이 얼마나 좋은가?”를 숫자로 표현하는 도구입니다. 하지만 모든 문제에 같은 지표를 쓰지는 않습니다. 예측 대상이 연속값인지, 정답 클래스인지, 순위 목록인지에 따라 적절한 지표가 달라집니다.

**핵심 질문:** 이 모델이 틀렸을 때 어떤 실수가 더 위험한가? 예를 들어 암 진단에서는 실제 환자를 놓치는 미탐이 위험하므로 **Recall** 이 중요하고, 스팸 필터에서는 정상 메일을 스팸으로 보내는 오탐이 문제라 **Precision** 도 중요합니다.

| 문제 유형  | 예시                  | 대표 지표                                           |
|--------|---------------------|-------------------------------------------------|
| 회귀     | 집값, 매출, 온도 예측       | MAE , MSE , RMSE , $R^2$ , MAPE                 |
| 분류     | 스팸 여부, 이탈 여부, 질병 여부 | Accuracy , Precision , Recall , F1 , ROC-AUC    |
| 군집     | 고객 세그먼트, 문서 묶기      | Silhouette , Davies-Bouldin , Calinski-Harabasz |
| 추천·랭킹  | 상품 추천, 검색 결과 순위     | Precision@K , Recall@K , MAP , NDCG             |
| NLP·생성 | 번역, 요약, 언어 모델       | BLEU , ROUGE , METEOR , Perplexity              |

## 2. 회귀 모델 지표

회귀는 숫자를 예측하는 문제입니다. 예측값과 실제값의 차이를 오차라고 하며, 대부분의 회귀 지표는 이 오차를 어떤 방식으로 요약할지에 관한 지표입니다.

### MAE Mean Absolute Error

실제값과 예측값 차이의 절댓값 평균입니다. “평균적으로 얼마만큼 틀렸는가?”를 직관적으로 보여줍니다.

단위: 타깃값과 같음 · 낮을수록 좋음

### MSE Mean Squared Error

오차를 제곱한 뒤 평균을 냅니다. 큰 오차에 더 큰 벌점을 주기 때문에 이상치에 민감합니다.

단위: 타깃값의 제곱 · 낮을수록 좋음

### RMSE Root Mean Squared Error

MSE 에 루트를 씌운 값입니다. 큰 오차에 민감하면서도 단위가 원래 타깃값과 같아 해석이 쉽습니다.

단위: 타깃값과 같음 · 낮을수록 좋음

### R<sup>2</sup> Score 결정계수

모델이 실제 데이터의 변동성을 얼마나 설명하는지 나타냅니다. 보통 1에 가까울수록 좋고, 0은 평균값만 예측하는 수준에 가깝습니다. 음수도 나올 수 있습니다.

단위: 없음 · 높을수록 좋음

### MAPE Mean Absolute Percentage Error

절대 오차를 실제값 대비 비율로 계산합니다. “평균적으로 몇 퍼센트 틀렸는가?”라고 말할 수 있어 비즈니스 보고에 자주 쓰입니다.

단위: % · 낮을수록 좋음 · 실제값이 0에 가까우면 불안정

**회귀 지표 선택 팁:** 큰 실수를 특히 싫어하면 **RMSE**, 오차 크기를 직관적으로 보고 싶으면 **MAE**, 설명력을 보고 싶으면 **R<sup>2</sup>**, 상대적인 퍼센트 오차가 중요하면 **MAPE** 를 봅니다.

### 3. 분류 모델 지표

분류는 데이터를 정해진 클래스 중 하나로 나누는 문제입니다. 분류 지표를 이해하려면 먼저 TP, FP, FN, TN 을 알아두면 좋습니다.

| 용어 | 뜻                              | 예: 질병 양성 예측      |
|----|--------------------------------|------------------|
| TP | Positive라고 예측했고 실제로 Positive   | 환자를 환자라고 맞춤      |
| FP | Positive라고 예측했지만 실제로는 Negative | 건강한 사람을 환자라고 오진  |
| FN | Negative라고 예측했지만 실제로는 Positive | 환자를 건강하다고 놓침     |
| TN | Negative라고 예측했고 실제로 Negative   | 건강한 사람을 건강하다고 맞춤 |

#### Accuracy 정확도

전체 데이터 중 맞춘 비율입니다. 클래스 비율이 균형적일 때 이해하기 쉽습니다.

높을수록 좋음

#### Precision 정밀도

Positive로 예측한 것 중 실제 Positive의 비율입니다. 오탐을 줄이고 싶을 때 중요합니다.

높을수록 좋음

#### Recall 재현율

실제 Positive 중 모델이 찾아낸 비율입니다. 미탐을 줄이고 싶을 때 중요합니다.

높을수록 좋음

#### F1 Score

Precision 과 Recall 의 조화평균입니다. 두 지표의 균형이 필요할 때 씁니다.

높을수록 좋음

#### ROC-AUC

분류 threshold를 여러 값으로 바꿔가며 성능을 종합한 지표입니다. 1에 가까울수록 좋고, 0.5는 무작위 분류에 가까운 수준으로 해석합니다.

#### PR-AUC

Precision-Recall 곡선 아래 면적입니다. Positive 클래스가 매우 적은 불균형 데이터에서는 ROC-AUC 보다 더 실무적인 정보를 줄 때가 많습니다.

### Log Loss Cross-Entropy Loss

모델이 낸 예측 확률의 품질을 평가합니다. 정답을 틀리면서 높은 확률로 확신했다면 큰 벌점을 받습니다.  
낮을수록 좋음

**주의:** 데이터가 심하게 불균형하면 **Accuracy** 만으로는 모델이 좋아 보이는 착시가 생깁니다. 예를 들어 정상 99%, 이상 1%인 데이터에서 전부 정상이라고 예측해도 정확도는 99%입니다.

## 4. 군집 모델 지표

군집은 정답 라벨 없이 비슷한 데이터끼리 묶는 비지도 학습 문제입니다. 따라서 군집 지표는 “같은 군집 안에서는 가까운가?”와 “다른 군집과는 잘 떨어져 있는가?”를 봅니다.

| 지표                      | 해석                                            | 좋은 방향   |
|-------------------------|-----------------------------------------------|---------|
| Silhouette Score        | 군집 내부 응집도와 군집 간 분리도를 함께 봅니다. 보통 -1에서 1 사이입니다. | 높을수록 좋음 |
| Davies-Bouldin Index    | 각 군집이 얼마나 잘 분리되어 있는지 평가합니다.                   | 낮을수록 좋음 |
| Calinski-Harabasz Index | 군집 간 분산과 군집 내 분산의 비율을 봅니다.                    | 높을수록 좋음 |

군집 평가는 숫자 지표만으로 끝내기 어렵습니다. 실제 업무에서는 군집별 프로파일을 보고 “해석 가능한 그룹인가?”까지 함께 확인하는 것이 좋습니다.

## 5. 추천·랭킹 지표

추천과 검색에서는 정답을 맞췄는지만큼이나 “좋은 항목이 얼마나 위에 나왔는가?”가 중요합니다. 그래서 보통 상위  $K$  개의 결과를 기준으로 지표를 계산합니다.

| 지표          | 무엇을 보는가                  | 사용 상황                     |
|-------------|--------------------------|---------------------------|
| Hit Rate    | 추천 목록 안에 정답 아이템이 포함됐는지   | 정답이 하나 또는 적을 때            |
| Precision@K | 상위 K개 중 관련 있는 항목의 비율     | 추천 슬롯이 제한적일 때             |
| Recall@K    | 관련 항목 전체 중 상위 K개에 포함된 비율 | 많은 관련 항목을 놓치지 않는 것이 중요할 때 |
| MAP         | 관련 항목이 앞쪽에 잘 배치됐는지       | 순위 품질을 평균적으로 평가할 때        |
| NDCG        | 관련성이 높은 항목을 더 위에 배치했는지   | 관련성 등급이 여러 단계일 때          |

## 6. 자연어 처리·생성 모델 지표

NLP와 생성 모델에서는 정답 문장과 생성 문장이 완전히 같지 않아도 좋은 답일 수 있습니다. 그래서 자동 지표는 참고용으로 쓰고, 사람 평가나 태스크별 품질 점검을 함께 보는 경우가 많습니다.

| 지표         | 주요 용도    | 해석                                               |
|------------|----------|--------------------------------------------------|
| BLEU       | 기계번역     | 생성 문장과 참조 문장의 n-gram 겹침을 평가합니다.                  |
| ROUGE      | 요약       | 정답 요약과 생성 요약이 얼마나 겹치는지 봅니다.                      |
| METEOR     | 번역·문장 생성 | 단어 일치 외에 어근, 동의어, 어순 등을 일부 고려합니다.                |
| Perplexity | 언어 모델    | 다음 단어 예측이 얼마나 어려운지 나타냅니다. 낮을수록 모델이 데이터를 잘 설명합니다. |

생성 모델 평가는 자동 지표 하나로 결론 내리기 어렵습니다. 정확성, 유용성, 안전성, 문체, 근거성 같은 기준을 별도로 정의하는 것이 좋습니다.

## 7. 실무에서 지표를 선택하는 방법

**1단계:** 문제 유형을 먼저 확인합니다. 회귀인지, 분류인지, 추천인지에 따라 후보 지표가 달라집니다.

**2단계:** 틀렸을 때의 비용을 따집니다. 오탐이 위험한지, 미탐이 위험한지, 큰 오차가 특히 문제인지 봅니다.

**3단계:** 데이터 분포를 확인합니다. 클래스 불균형, 이상치, 0에 가까운 실제값이 지표 해석을 흔들 수 있습니다.

**4단계:** 하나의 지표만 보지 않습니다. 주 지표 하나와 보조 지표 몇 개를 함께 봅니다.

**5단계:** 비즈니스 언어로 번역합니다. “RMSE 12.4”가 실제 업무에서 허용 가능한 오차인지 설명할 수 있어야 합니다.

## 8. 점수 범위와 결과 해석

성능 지표는 숫자 자체보다 “이 숫자가 어떤 방향으로 좋아지는가?”와 “어느 정도면 위험 신호인가?”를 함께 읽어야 합니다. 어떤 지표는 1에 가까울수록 좋고, 어떤 지표는 0에 가까울수록 좋습니다. 또 일부 지표는 음수가 나올 수 있으며, 이때는 모델이나 데이터 설계를 다시 확인해야 합니다.

### 회귀 지표 해석

| 지표                   | 값의 범위          | 좋은 방향        | 해석 방법                                                          |
|----------------------|----------------|--------------|----------------------------------------------------------------|
| MAE                  | 0 이상           | 0에 가까울수록 좋음  | 평균적으로 실제값과 얼마나 차이 나는지 봅니다. 예: MAE가 5라면 평균적으로 약 5 단위 틀린다는 뜻입니다. |
| MSE                  | 0 이상           | 0에 가까울수록 좋음  | 오차를 제곱하므로 큰 오차에 민감합니다. 단위가 제곱이라 직관적 해석은 어렵습니다.                 |
| RMSE                 | 0 이상           | 0에 가까울수록 좋음  | 큰 오차를 더 강하게 반영합니다. 단위가 타겟과 같아 “대략 몇 단위 틀리는가”로 해석하기 좋습니다.       |
| R <sup>2</sup> Score | 보통 1 이하, 음수 가능 | 1에 가까울수록 좋음  | 1은 거의 완벽한 설명, 0은 평균값만 예측하는 기준 모델 수준, 음수는 평균값 예측보다도 못한 상태입니다.   |
| MAPE                 | 0% 이상          | 0%에 가까울수록 좋음 | 평균적으로 몇 퍼센트 틀렸는지 봅니다. 실제값이 0에 가까우면 값이 과도하게 커질 수 있습니다.          |

**회귀 해석 주의:** R<sup>2</sup> 가 음수라고 해서 코드가 반드시 오류라는 뜻은 아니지만, 현재 모델이 단순 평균 예측보다 못하다는 강한 경고입니다. 피처, 전처리, train/test 분리, 데이터 누수를 다시 확인해야 합니다.

## 분류 지표 해석

| 지표        | 값의 범위         | 좋은 방향        | 해석 방법                                                          |
|-----------|---------------|--------------|----------------------------------------------------------------|
| Accuracy  | 0~1 또는 0~100% | 1에 가까울 수록 좋음 | 전체 중 맞춘 비율입니다. 0.9는 90%를 맞췄다는 뜻입니다.                            |
| Precision | 0~1           | 1에 가까울 수록 좋음 | Positive라고 예측한 것 중 실제 Positive 비율입니다. 낮으면 오탐이 많다는 뜻입니다.        |
| Recall    | 0~1           | 1에 가까울 수록 좋음 | 실제 Positive 중 찾아낸 비율입니다. 낮으면 미탐이 많다는 뜻입니다.                     |
| F1 Score  | 0~1           | 1에 가까울 수록 좋음 | Precision과 Recall의 균형입니다. 둘 중 하나가 매우 낮으면 F1도 낮아집니다.            |
| ROC-AUC   | 0~1           | 1에 가까울 수록 좋음 | 0.5는 무작위 수준, 1은 거의 완벽한 구분입니다. 0.5보다 낮으면 클래스 방향이나 학습 상태를 의심합니다. |
| PR-AUC    | 0~1           | 1에 가까울 수록 좋음 | 불균형 데이터에서 Positive 클래스를 얼마나 잘 찾는지 보는 데 유용합니다.                  |
| Log Loss  | 0 이상          | 0에 가까울 수록 좋음 | 확률 예측의 품질입니다. 틀린 답을 높은 확률로 확신할수록 값이 크게 나빠집니다.                  |

**분류 해석 팁:** Accuracy가 높아도 좋은 모델이 아닐 수 있습니다. 예를 들어 이상 데이터가 1%뿐이면 전부 정상이라고 예측해도 Accuracy는 99%가 됩니다. 이럴 때는 Recall, Precision, F1, PR-AUC를 함께 봐야 합니다.

## 군집, 추천, NLP 지표 해석

| 지표                     | 값의 범위           | 좋은 방향       | 해석 방법                                                        |
|------------------------|-----------------|-------------|--------------------------------------------------------------|
| Silhouette Score       | -1~1            | 1에 가까울수록 좋음 | 1에 가까우면 군집이 잘 분리된 상태, 0 근처는 경계가 애매한 상태, 음수는 잘못 묶였을 가능성이 큼니다. |
| Davies-Bouldin Index   | 0 이상            | 낮을수록 좋음     | 군집 내부는 조밀하고 군집끼리는 멀수록 값이 낮아집니다.                              |
| Precision@K , Recall@K | 0~1             | 1에 가까울수록 좋음 | 상위 K개 추천 결과 중 관련 항목이 얼마나 포함됐는지 봅니다.                          |
| NDCG                   | 0~1             | 1에 가까울수록 좋음 | 관련성이 높은 항목을 상위에 잘 배치했는지 봅니다.                                 |
| BLEU , ROUGE           | 보통 0~1 또는 0~100 | 높을수록 좋음     | 정답 문장과 생성 문장의 겹침을 봅니다. 높다고 항상 사람이 보기에 좋은 문장이라는 뜻은 아닙니다.      |
| Perplexity             | 0보다 큼           | 낮을수록 좋음     | 언어 모델이 다음 단어를 얼마나 덜 헛갈리는지 나타냅니다. 낮을수록 예측이 안정적입니다.            |

## 결과값을 읽을 때의 기본 원칙

**1에 가까울수록 좋은 지표:** Accuracy, Precision, Recall, F1, ROC-AUC, PR-AUC, NDCG, Silhouette Score 등이 있습니다.

**0에 가까울수록 좋은 지표:** MAE, MSE, RMSE, MAPE, Log Loss, Davies-Bouldin Index, Perplexity 등이 있습니다.

**음수가 의미 있는 지표:**  $R^2$  와 Silhouette Score 는 음수가 나올 수 있습니다. 보통 모델이나 군집 결과가 좋지 않다는 신호입니다.

**숫자는 기준 모델과 비교:** 점수 하나만 보지 말고, 단순 평균 예측이나 다수 클래스 예측 같은 baseline보다 나은지 확인해야 합니다.

**업무 단위로 번역:** RMSE 12.4가 좋은지는 도메인에 따라 다릅니다. 원, 명, 시간, 점수처럼 실제 단위로 해석해야 합니다.

## 9. 빠른 요약표

| 상황              | 추천 지표                       | 이유                            |
|-----------------|-----------------------------|-------------------------------|
| 집값·매출처럼 연속값 예측  | MAE , RMSE , R <sup>2</sup> | 오차 크기와 설명력을 함께 볼 수 있습니다.      |
| 큰 오차를 특히 줄이고 싶음 | RMSE                        | 오차를 제곱하므로 큰 실수에 민감합니다.        |
| 클래스가 균형적인 일반 분류 | Accuracy , F1               | 전체 정답률과 균형 성능을 함께 봅니다.        |
| 오탐을 줄이는 것이 중요   | Precision                   | Positive 예측의 신뢰도를 보여줍니다.      |
| 미탐을 줄이는 것이 중요   | Recall                      | 실제 Positive를 얼마나 찾아냈는지 보여줍니다. |
| 불균형 분류          | F1 , PR-AUC , Recall        | 정확도 착시를 줄이고 희소 클래스 성능을 봅니다.   |
| 추천·검색 상위 결과 평가  | Precision@K , NDCG          | 상위 노출 결과의 품질과 순서를 평가합니다.      |
| 요약·번역 자동 평가     | ROUGE , BLEU , 사람 평가        | 문장 겹침과 실제 품질 판단을 함께 봅니다.      |

마무리: 좋은 지표는 모델의 숫자 성능뿐 아니라, 실제 의사결정에서 중요한 실수를 잘 드러내야 합니다. 그래서 지표 선택은 모델링의 부록이 아니라 문제 정의의 일부입니다.